

PROBLEMA DE MINIMIZAÇÃO/MAXIMIZAÇÃO DE FUNÇÃO CUSTO/OBJETIVO

Autor 1: Luiz Eduardo Alves Camurça

Resumo

A primeira seção do trabalho final da cadeira de Inteligência Artificial Computacional aborda um problema comum da computação: Encontrar valores para um conjunto de variáveis de decisão capazes de minimizar ou maximizar uma função objetivo. Neste trabalho foram implementados três algoritmos: Hill Climbing, Busca Aleatória Local e Busca Aleatória Global. Os algoritmos foram aplicados a seis funções de otimização. Cada algoritmo foi executado em múltiplas rodadas independentes, tendo suas métricas armazenadas para comparação de comportamento.

Introdução

Problemas de otimização consistem na busca pela melhor solução possível dentro de um espaço definido. Em muitos casos, a dimensão do problema ou a complexidade da função objetivo tornam inviável a utilização de métodos exatos, motivando o uso de técnicas heurísticas e meta-heurísticas.

As meta-heurísticas são estratégias gerais de busca que podem ser adaptadas para diferentes tipos de problemas. Diferente de algoritmos específicos para um único domínio, essas abordagens exploram o espaço de soluções por meio de mecanismos probabilísticos ou determinísticos que buscam o equilíbrio entre exploração e intensificação.

Neste trabalho foram estudados três algoritmos de busca para domínios contínuos: Hill Climbing, Busca Aleatória Local e Busca Aleatória Global. O objetivo consiste em analisar o comportamento desses métodos na resolução de funções de minimização e maximização, avaliando sua capacidade de encontrar soluções ótimas ou sub ótimas dentro de um número máximo de iterações.

Metodologia

Problemas de Otimização

Foram considerados seis problemas de otimização contínua propostos pelo enunciado. Cada problema é definido por uma função específica e por restrições de domínio para as variáveis independentes.

Representação da Solução

Cada solução candidata foi representada por um vetor $x = (x_1, x_2)$, onde cada componente representa uma variável independente da função objetivo. Todos os candidatos gerados pelo algoritmo foram validados de acordo com os limites inferiores e superiores definidos pelo problema.

Hill Climbing

O algoritmo Hill Climbing foi implementado utilizando como ponto inicial o limite inferior do domínio das variáveis. A geração de vizinhos foi realizada através de perturbações controladas pelo hiper parâmetro ϵ , responsável por definir a vizinhança da solução. A cada iteração, o algoritmo compara a solução atual com o candidato gerado e mantém apenas soluções que apresentam melhoria em relação ao valor da função objetivo.

Busca Aleatória Local(LRS)

A Busca Aleatória Global foi implementada através da geração de candidatos completamente independentes da solução atual. A cada iteração, um novo ponto é sorteado uniformemente dentro do domínio do problema e comparado com a melhor solução conhecida até então.

Critério de Parada

Todos os algoritmos utilizam limite máximo de 1000 iterações e critério de parada antecipada baseado na ausência de melhorias durante um número pré-definido de iterações consecutivas.

Lógica de Testes

Cada combinação entre algoritmo e função objetivo foi executada em 100 rodadas independentes. Cada execução registrou melhor solução encontrada, valor da função objetivo, quantidade de iterações e tempo de execução.

Resultados e Discussão

Função 1 - $f(x_1, x_2) = x_1^2 + x_2^2$:

Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC	62,78	583	62,78	247,61
LRS	16,45	4568,94	16,45	3249,66
GRS	0,33	80,64	0,33	85,45



A tabela acima mostra os resultados obtidos para as rodadas de execução com os valores de hiperparâmetros iniciais sugeridos pelo enunciado do trabalho: $\varepsilon = 0,1$ e $\sigma = 1$.


Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC	9,2e-5	0,02	9,3e-05	0,028
LRS	9,6e-5	0,003	0,003	0,003
GRS	391,61	80,64	0,33	85,45

A tabela seguinte mostra os valores obtidos para os hiperparâmetros $\varepsilon = 2$ e $\sigma = 0,5$.

O valor atribuído para ε se deu porque a pequena amplitude de $\varepsilon = 0,1$ limitava significativamente a capacidade de deslocamento da solução inicial até o ótimo global. Considerando que o algoritmo inicia no limite inferior do espaço de busca, valores muito reduzidos exigem um número excessivo de melhorias para alcançar a região ótima.

Para σ , valores elevados produzem perturbações muito grandes, fazendo o algoritmo se comportar de forma parecida ao de busca global aleatória. Por outro lado, valores muito pequenos reduzem a capacidade de exploração do espaço de busca. $\sigma = 0,5$ proporcionou um bom equilíbrio.





Os resultados obtidos para essa função demonstram a importância dos mecanismos de exploração local em problemas contínuos convexos. Tanto o Hill Climbing quanto o Local Random Search foram capazes de convergir para regiões muito próximas do ótimo global, superando amplamente o Global Random Search. Entre os métodos avaliados, o Local Random Search apresentou o melhor equilíbrio entre precisão e estabilidade, alcançando os menores valores médios e a melhor solução individual do experimento. O Hill Climbing também apresentou desempenho consistente, embora ligeiramente inferior ao LRS. Já o Global Random Search mostrou-se limitado pela ausência de refinamento local, confirmando que estratégias puramente aleatórias tendem a ser menos eficientes em funções unimodais de otimização contínua.



Função 2 - $f(x_1, x_2) = e^{-(x_1^2 + x_2^2)} + 2 \cdot e^{-(x_1 - 1.7)^2 + (x_2 - 1.7)^2}$


Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC	1,006	1,006	1,006	5,88e-5
LRS	2,002	1,97	1,976	0,03
GRS	2,000	1,83	1,838	0,15

A tabela acima mostra os resultados obtidos para as rodadas de execução com os valores de hiperparâmetros iniciais sugeridos pelo enunciado do trabalho: $\epsilon = 0,1$ e $\sigma = 1$.

Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC	1,006	1,006	1,006	9,88e-5
LRS	2,003	1,66	2,003	0,47
GRS	2,001	1,84	1,92	0,15

A tabela seguinte mostra os valores obtidos para os hiperparâmetros $\epsilon = 0,1$ e $\sigma = 0,1$. A escolha desses valores foi motivada pelas características específicas da função. Diferentemente da função 1, cujo domínio é amplo e exige deslocamentos maiores para alcançar a região ótima, a função 2 possui um domínio reduzido e apresenta dois máximos distintos: um máximo local próximo da origem e um máximo global localizado aproximadamente em (1,7; 1,7). Dessa forma, valores excessivamente altos para ϵ e σ poderiam fazer com que os algoritmos ultrapassassem regiões promissoras sem realizar o refinamento adequado, enquanto valores muito pequenos dificultariam a exploração do espaço de busca.





Os resultados obtidos para esta função evidenciam as diferenças entre algoritmos de busca local e métodos com maior capacidade exploratória. O Hill Climbing apresentou comportamento extremamente consistente, convergindo em praticamente todas as execuções para a região próxima da origem. Entretanto, apesar da elevada estabilidade observada, o algoritmo encontrou apenas o máximo local da função, obtendo valores próximos de 1,006. Esse resultado demonstra que métodos de busca local determinística tendem a permanecer presos em ótimos locais quando não possuem mecanismos para escapar dessas regiões.

De modo geral, a função 2 demonstrou claramente a influência dos ótimos locais no desempenho dos algoritmos de otimização. Enquanto o Hill Climbing ficou preso de forma consistente no máximo local, os métodos estocásticos foram capazes de explorar diferentes regiões do espaço de busca e encontrar com maior frequência o ótimo global. Entre os algoritmos avaliados, o Global Random Search apresentou o melhor desempenho médio, enquanto o Local Random Search obteve a melhor solução individual do experimento.

Função 3 - $f(x_1, x_2) = -20 \cdot e^{-0.2 \cdot \sqrt{0.5 \cdot (x_1^2 + x_2^2)}} - e^{0.5 \cdot (\cos(2\pi x_1) + \cos(2\pi x_2))} + 20 \cdot e$



Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC	15,95	15,96	15,96	0,0005
LRS	0,01	0,61	0,01	0,4
GRS	0,16	3,08	3,08	1,05


A tabela acima mostra os resultados obtidos para as rodadas de execução com os valores de hiperparâmetros iniciais sugeridos pelo enunciado do trabalho: $\epsilon = 0,1$ e $\sigma = 1$.

Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC	15,95	15,96	15,96	0,0006
LRS	0,01	9,64	0,01	4,83
GRS	0,18	3,10	0,18	1,14

A tabela seguinte mostra os valores obtidos para os hiperparâmetros $\epsilon = 0,5$ e $\sigma = 0,3$.

A escolha desses valores foi motivada pelas características da função, que possui um grande número de mínimos locais distribuídos ao longo do espaço de busca. Por ser altamente multimodal, torna o processo de otimização mais complexo. Valores muito pequenos para ϵ e σ tenderiam a restringir excessivamente o movimento dos algoritmos, aumentando a probabilidade de ficarem presos a mínimos locais.





O Local Random Search apresentou desempenho superior ao Hill Climbing, sendo capaz de localizar regiões muito próximas do ótimo global em algumas execuções. A melhor solução encontrada apresentou valor de 0,013, obtido em um ponto extremamente próximo da origem, onde se encontra o mínimo global da função. Entretanto, a elevada dispersão dos resultados indica que o algoritmo alternou entre convergências bem-sucedidas e aprisionamentos em mínimos locais, característica esperada para métodos estocásticos aplicados a funções altamente multimodais.



Função 4 - $f(x_1, x_2) = (x_1^2 - 10 \cdot \cos(2\pi x_1) + 10) + (x_2^2 - 10 \cdot \cos(2\pi x_2) + 10)$


Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC	49,74	49,76	49.74	0,01
LRS	0,03	2,03	0,03	1,91
GRS	0,34	4,27	0,34	2,44

A tabela acima mostra os resultados obtidos para as rodadas de execução com os valores de hiperparâmetros iniciais sugeridos pelo enunciado do trabalho: $\epsilon = 0,1$ e $\sigma = 1$.

Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC	0,06	3,70	0,06	5,02
LRS	0,01	4,45	0,01	4,61
GRS	0,17	4,36	0,17	2,21

A tabela seguinte mostra os valores obtidos para os hiperparâmetros $\epsilon = 1$ e $\sigma = 0,5$.





Os resultados obtidos para esta função demonstram a dificuldade imposta pela grande quantidade de mínimos locais presentes. O Hill Climbing apresentou o melhor desempenho médio entre os algoritmos avaliados, obtendo média de 3,705 e demonstrando boa capacidade de convergência para regiões próximas do ótimo global. Embora seja um método puramente local, o valor de ϵ adotado permitiu que o algoritmo realizasse deslocamentos suficientemente amplos para evitar parte dos mínimos locais presentes na função.



Função 5 - $f(x_1, x_2) = x_1 \cdot \cos(x_1) \cdot 20 + 2 \cdot e^{-(x_1)^2 - (x_2 - 1)^2} + 0.01 \cdot x_1 \cdot x_2$


Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC	62,78	1,43	1,43	1,06e-6
LRS	16,45	1,007	0,97	0,43
GRS	0,33	1,44	1,97	0,2

A tabela acima mostra os resultados obtidos para as rodadas de execução com os valores de hiperparâmetros iniciais sugeridos pelo enunciado do trabalho: $\epsilon = 0,1$ e $\sigma = 1$.

Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC		0,02	9,3e--05	0,028
LRS		0,003	0,003	0,003
GRS		80,64	0,33	85,45

A tabela seguinte mostra os valores obtidos para os hiperparâmetros $\epsilon = 0,5$ e $\sigma = 0,5$. A escolha desses valores foi motivada pela presença simultânea de componentes oscilatórios e exponenciais na função. O termo exponencial gera uma região de máximo bem definida próxima ao ponto (0,1), enquanto os demais termos introduzem irregularidades e máximos locais ao longo do domínio. Dessa forma, valores moderados para ϵ e σ foram adotados para equilibrar a capacidade de exploração do espaço de busca com o refinamento das soluções encontradas.





De maneira geral, a Função 5 evidenciou a limitação dos métodos puramente locais diante da presença de múltiplos máximos. Enquanto o Hill Climbing permaneceu preso em uma solução subótima, os algoritmos estocásticos conseguiram explorar regiões mais promissoras do espaço de busca. O Local Random Search encontrou a melhor solução individual do experimento, enquanto o Global Random Search apresentou o melhor equilíbrio entre qualidade média e robustez das soluções obtidas.

Função 6 - $f(x_1, x_2) = x_1 \cdot \sin(4\pi x_1) - x_2 \cdot \sin(4\pi x_2 + \pi) + 1$


Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC	1	1	1	3e-16
LRS	6,24	4,85	6,62	0,76
GRS	6,09	4,89	6,09	0,54

A tabela acima mostra os resultados obtidos para as rodadas de execução com os valores de hiperparâmetros iniciais sugeridos pelo enunciado do trabalho: $\epsilon = 0,1$ e $\sigma = 1$.


Algoritmos	Melhor Valor	Média	Moda	Desvio Padrão
HC	6,20	3,31	6,20	1,32
LRS	6,24	4,12	6,24	1,10
GRS	6,25	4,9	6,25	0,57


A tabela seguinte mostra os valores obtidos para os hiperparâmetros $\epsilon = 0,9$ e $\sigma = 0,5$. Inicialmente foram realizados testes utilizando valores menores para ϵ . Entretanto, observou-se que pequenas amplitudes de vizinhança limitavam significativamente a capacidade de deslocamento do Hill Climbing em uma superfície altamente oscilatória. Como consequência, o algoritmo permanecia preso em regiões próximas ao ponto inicial. Após experimentação, verificou-se que $\epsilon = 0,9$ proporcionou melhor equilíbrio entre exploração e refinamento local, permitindo que o algoritmo alcançasse regiões próximas ao máximo global da função.

Distribuição das execuções - F6 - Sinusoidal



Convergência média - F6 - Sinusoidal





O Global Random Search apresentou o melhor desempenho médio entre os algoritmos avaliados, alcançando média de 4,938 e melhor valor de 6,250. A combinação entre o domínio reduzido da função e a elevada quantidade de máximos distribuídos pelo espaço de busca favoreceu a estratégia de exploração global, permitindo que o algoritmo localizasse com frequência soluções de alta qualidade.

Conclusão

Neste trabalho foram implementados três algoritmos meta-heurísticos para resolução de problemas de otimização. Os experimentos realizados permitiram observar diferenças importantes entre busca local e amostragem aleatória. O Hill Climbing apresentou comportamento fortemente dependente da escolha da vizinhança, com boa eficiência em superfícies simples, porém, maior dificuldade de lidar com ótimos locais. A busca Aleatória Local apresentou maior capacidade de exploração controlada, enquanto a global demonstrou maior diversidade de soluções ao custo de uma convergência mais lenta.

No geral, os resultados mostram a importância de equilibrar exploração e intensificação em algoritmos de otimização.